# 제 9장. 표집분포 (Sampling distribution)

- 주어진 표본으로부터 모집단의 성격을 알아내고자 하는 추론(inference)이 통계학의 가장 핵심부분이다.

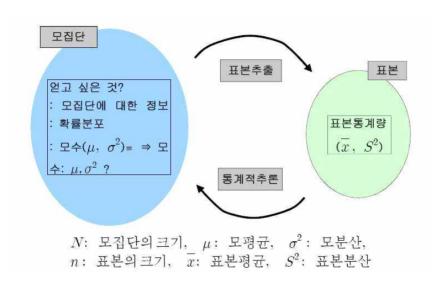
모수 : 수치로 표현되는 모집단의 특성 / 확률밀도함수(모집단의 모양) 의 특성을 결정 but 일반적으로 모르는 값

통계량: 표본의 관측값들에 의하여 결정되는 양

- \* 통계량의 값은 모수의 참값과는 차이가 있다.
- \* 통계량의 값은 그 당시 추출된 표본에 영향 받음.
- \* 통계량의 값은 표본에 따라 값이 변한다.

-notation) N : 모집단의 크기,  $\mu$  : 모평균,  $\sigma^2$  : 모분산, n : 표본의 크기,  $\overline{x}$  : 표본평균,  $S^2$  : 표본분산

### -모집단과 표본의 관계



Example) 신도시를 계획하려는 사람이 근로자드르이 집에서 직장까지의 평균 통근거리가 얼마나 되는지 알아보려고 한다고 하자.

-관심의 대상 : 전체 모집단의 평균 통근거리 (모평균 :  $\mu$ )

-80명의 근로자를 표본추출하여 이들로부터 통근거리를 조사하면

표본평균 :  $\overline{x} = 12km$ 

- -또 다른 80명의 근로자를 조사한다면 표본평균값이 달라짐.
- ightarrow 한 번의 표본추출로 근로자들의 집에서 직장까지의 평균 통근거리는 12km 라고 추

### 표집(표본)분포(Sampling distribution)

한 모집단에서 동일한 크기 n 으로 뽑을 수 있는 모든 가능한 표본에서 통계량(statistic) 을 계산할 때, 이 통계량의 확률분포를 의미한다.

→모집단의 분포에 영향을 받고, 표본 크기에도 영향을 받는다.

### 1. 표본평균의 표집분포

### 표본평균의 성질

모평균이  $\mu$  이고 모분산이  $\sigma^2$  인 모집단에서 크기 n 의 확률표본  $X_1, X_2, \cdots, X_n$ 을 얻었을 때 표본평균  $\overline{X}$  의 기댓값과 분산은 다음과 같다.

$$E(\overline{X}) = \mu$$
,  $Var(\overline{X}) = \frac{\sigma^2}{n}$ ,  $sd(\overline{X}) = \frac{\sigma}{\sqrt{n}}$ 

(n의 값이 커질수록 표준오차가 작아진다.

- $\rightarrow$  표본평균의 평균(기댓값) $E(\overline{X})$ =모평균  $\mu$
- → 표본평균의 표준편차(표준오차)에 대하여 표준오차가작다 ⇔ 어떤표본이뽑히느냐에관계없이 표본평균이크게변동하지않는다.

⇔ 모평균에 대한 정확성이 높은 추측값

### 모집단이 정규분포인 경우

정규분포  $N(\mu, \sigma^2)$ 을 따르는 모집단에서 크기 n 인 표본의 표본평균  $\overline{X}$  의 분포는 다음과 같다.

$$\overline{X} \sim N(\mu, \frac{\sigma^2}{n})$$

$$Z = \frac{\overline{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \sim N(0, 1)$$

→ 모집단이 정규분포를 따를 때, 표본의 평균은 표본의 개수와 상관없이 항상 정규분포를 따른다.

## 모집단이 정규분포가 아닌 경우

Theorem 중심극한정리 (Central limit theorem)

평균이  $\mu$  이고 분산이  $\sigma^2$  인 임의의 모집단에서 표본의 크기 n이 충분히 크면  $(30 \le n)$ ,

표본평균 X 는 근사적으로 정규분포  $N(\mu, \frac{\sigma^2}{n})$ 을 따른다. 이를 표준화하여 나타내면 다음과 같다.

$$\frac{\overline{X} - \mu}{\sigma / \sqrt{n}} \sim N(0, 1)$$

- Example) 어느 대학교 입학생 1000명의 평균 수능성적은 315점, 분산은 400점이다. 크기 50의 표본을 추출하였을 때표본평균의 기댓값과 분산을 구하라.
- Example) A대학의 건물 엘레베이터에는 다음과 같은 문구가 적혀있다. "정격 하중 1.350kg", "정원 20명". 이 때 20명의 몸무게가 과연 1.350kg을 넘을 확률이 얼마나 되는가? A대학 구성원들의 평균 몸무게는 64kg 이고 표준편차는 10kg인 정규분포를 따른다고 가정하자.

Example) 평균이 82이고 분산이 144인 모집단에 대하여 생각하면

- 1) 크기 64인 표본이 임의로 추출되었다고 할 때 표본평균이 80.8에서 83.2사이에 있을 확률?
- 2) 크기 100일 때 표본평균이 80.8에서 83.2사이에 있을 확률?

### 2. 표본비율의 표집분포

- 성공확률이 p 인 베르누이 시행으로부터 얻은  $X_1, X_2, \cdots, X_n$ 의 합계를 X라 하면 (즉, 베르누이 시행의 결과는 성공과 실패뿐이고, 성공을 1, 실패를 0 이라 하면)

표본의 합  $X = \sum_{i=1}^n X_i$  는 성공횟수가 되어 이항분포를 따른다.  $X \sim B(n,p)$ 

## 표본비율의 표집분포

p : 모비율(population proportion),  $\bar{p}$  : 표본비율(sample proportion)

$$\hat{p} = \frac{\sum_{i=1}^{n} X_i}{n} = \frac{X}{n}$$

$$ightarrow$$
 표본비율의 평균 :  $\mu_{\hat{p}} = E(\hat{p}) = E\left[\frac{X}{n}\right] = \frac{1}{n}np = p$ 

$$\rightarrow$$
 표본비율의 분산 :  $\sigma_{\hat{p}}^2 = Var(\hat{p}) = Var\left[\frac{X}{n}\right] = \frac{1}{n^2}np(1-p) = \frac{p(1-p)}{n}$ 

### 표본크기가 큰 경우

표본크기 n이 충분히 큰 경우, 표본비율  $\hat{p}$  는 근사적으로 평균이 p이고 표준편차가  $\sqrt{\frac{p(1-p)}{n}}$  인 정규분포를 따른다.

$$\frac{\hat{p}-p}{\sqrt{p(1-p)/n}} \approx N(0,1)$$

Example) 어느 대학의 사회계열 학생들을 대상으로 하는 통계학 입문 강의는 70명씩 10개반으로 나누어 진행되고 있다. 사회계열 학생들은 각자 수강하려는 모든 과목들의 시간표를 고려하여 다른 교양과목이나 전공과목 들과 시간이 겹치지 않도록 10개의 반 중 어느 하나를 수강해야 한다. 어느 특정 통계학입문반의 여학생수가 과반이상이 될 확률을 구하여라. 사회계열 전체 여학생의 비율은 0.54이다.

sol) 
$$p = 0.54$$
,  $\hat{p} \sim N \left( 0.54, \frac{0.54 \times 0.46}{70} \right) = N(0.54, 0.00355)$   
 $P(\hat{p} \le 0.5) = P \left( Z \ge \frac{0.5 - 0.54}{\sqrt{0.00355}} \right) = P(Z \ge -0.67) = 0.7486$ 

Example) 어떤 작업을 완료하는데 걸리는 시간은 평균이 30분, 표준편차가 9분인 정규분포를 따른다. 25명의 작업자를 임의로 추출했을 때 평균작업시간이 28분에서 33분 사이일 확률을 구하시오.

Example) 한 교통에 관한 연구에서 승용차 한 대당 탑승객의 수는 평균 1.75명이고 표준편차는 0.65명이었다. 승용 차 50대를 추출하여 조사하였을 때 평균 탑승객의 수가 2명 이상일 확률을 구하시오.

Example) 어느 대학교의 총학생회장 선거에서의 투표울은 60%라고 하자. 이 대학교의 투표율을 알아보기 위해서 78명의 학생을 대상으로 조사한 결과 투표율이 0.5와 0.7사이에 있을 확률을 구하시오.

# 제 10 장. 통계적 추론 (Statistical Inference)

- -통계적 추론이란 표본이 갖고 있는 정보를 분석하여 모수에 관한 결론을 유도하고, 모수에 대한 가설의 옳고 그름을 판단하는 것을 말한다.
- \* 통계적 추론  $= egin{cases} (1) 모수의 추정 \\ (2) 모수에 대한 가설검정 \end{cases}$

# 1. 모평균에 대한 추정

## 추정 (Estimation)

표본으로부터 정보를 이용하여 모집단의 성질을 나타내는 수치인 모수를 예측하는 것 즉, N개의 원소로 구성된 모집단에서 n개의 표본을 추출한 후, 이를 토대로 모집단의 모수를 예측하는 과정이다

- $\rightarrow$ 1) 모평균의 점 추정 (point estimation) :  $\mu$ 를 하나의 값으로 추정 ( $\hat{\mu}$ = 38)
- $\rightarrow$ 2) 모평균의 구간 추정 (interval estimation) :  $\mu$ 를 포함할만한 적당한 구간을 정한다. ( $36 < \mu < 40$ )

### 점추정 (Point Estimation)

추정하고자 하는 하나의 모수에 대하여 n개의 확률변수로 하나의 통계량을 만들고, 주어진 표본으로부터 그 값을 계산하여 하나의 수치를 제시하려고 하는 것이다

- → 추정량(estimator) : 모수를 추정하기 위해 만들어진 통계량
- → 추정치(estimate) : 표본에서 구한 추정량의 값

Example) 해당 도시의 중학교 1학년 남학생의 평균키 추정량 :  $\overline{X} = \frac{1}{n}(X_1 + \dots + X_n)$ 

주어진 표본이 30명이라 하고  $\overline{x} = 160.20cm$ 이라 하면 평균키의 추정치는 160.53cm이다.

\*\*표준오차(Standard error, S.E.) : 추정량의 정확도를 측정하는 도구. (추정량의 표준면차=표준오차)

Example) 추정량이 표본평균인 경우 표본평균의 표준편차인  $\frac{\sigma}{\sqrt{n}}$  이 표준오차이다.  $(S.E.(\overline{X}) = \frac{\sigma}{\sqrt{n}})$ 

- $\overline{X}$ 를 가지고  $\mu$ 를 추정할 경우 n이 클수록 표준오차가 작아져서 좀 더 정확한 추정이 가능해진다.
- $\rightarrow$  추정된 표준오차 :  $\frac{s}{\sqrt{n}}$  , (  $s=\sqrt{\frac{1}{n-1}\sum_{i=1}^n(x_i-\overline{x})^2}$  )

 $(\sigma$ 를 모르는 경우  $\sigma$ 의 추정량으로 표본표준편차 s를 사용 :  $\hat{\sigma}=s$ )

### 모평균에 대한 점추정 요약

모수 : 모집단의 평균  $\mu$ 

자료 : 평균이  $\mu$ 이고 표준편차가  $\sigma$ 인 모집단에서 임의추출한 표본  $X_1, \cdots, X_n$ 

추정량 : 표본평균  $\overline{X}$ 

표준오차 :  $S.E.(\overline{X}) = \frac{\sigma}{\sqrt{n}}$ , 추정된 표준오차 :  $\frac{s}{\sqrt{n}}$ 

ightarrow임의표본(random sample) : 모집단으로부터 임의추출된 크기가 n인 표본  $X_1, \cdots, X_n$ 이 서로 독립, 모두 모집단의 분포와 같은 분포를 갖는 것

Example) 어느 전기부품공장에서 자사의 제품 중 전기퓨즈의 평균수명( $\mu$ )을 알아보기 위해 40개의 표본을 추출하고 그 수명( $x_i$ )를 조사하여 다음과 같은 결과를 얻었다.

$$\Sigma x_i = 88 \qquad \quad \Sigma x_i^2 = 212$$

평균수명을 추정하고 그 추정량의 표준오차를 구하라.

sol) 평균수명 $(\mu)$ 의 추정량은 표본평균 $(\overline{X})$ 이므로  $\mu$ 의 추정치 :  $\overline{x} = \frac{88}{40} = 2.2$ 

모집단의 표준편차가 알려져 있지 않으므로 표본표준편차를 이용하여 표준오차를 추정한다. 우선,

$$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^{n} (x_i - \overline{x})^2} = \sqrt{\frac{1}{39} (212 - 40(2.2)^2)} = 0.687$$

따라서 표본평균의 추정된 표준오차는  $\frac{s}{\sqrt{n}} = \frac{0.687}{\sqrt{40}} = 0.109$  이다.

### \*\*점추정량의 선택 기준 (추정량의 성질)

#### (1) 불편성(Unbiasedness)

- 어떤 추정량  $\hat{\theta}$  가  $E(\hat{\theta}) = \theta$  를 만족하면  $\hat{\theta}$  를  $\theta$ 의 **불편추정량(undiased estimator)** 이라 한다.
- 추정량의 기댓값이 모수와 같이 않을 때 **편의(bias)** 가 있다고 표현한다.
- (2) 효율성(Efficiency) : 추정량의 표준오차(표준편차)가 작은 것
- 추정량  $\hat{\theta}$ 의 표준오차를  $S.E.(\hat{\theta})$ 라 하면, 모수  $\theta$ 의 불편추정량  $\hat{\theta_1}, \hat{\theta_2}$  에 대하여  $S.E.(\hat{\theta_1}) < S.E.(\hat{\theta_2}) \Leftrightarrow \hat{\theta_1} \ \in \ \hat{\theta_2}$  보다 더 **효율성 있는 추정량** 이라 한다.

#### (3) 일치성(Consistency)

- 표본 크기 n이 증가함에 따라 통계량이 점차 모수에 접근하게 될 때 그 통계량을 **일치추정량** 이라 한다.
- 크기가 n인 표본에서 구한 통계량을  $\hat{\theta_n}$  이라 할 때,  $\lim_{n \to \infty} E(\hat{\theta_n} \theta) = 0$
- → 편의 : 추정량이 모수에 근접하지 않고 한쪽으로 기울어져 치우친 상태
- → '일치성'이란 표본 크기가 클 수록 추정량이 보다 신뢰성이 있음을 의미

모수(parameter)	추정량(estimator)	성질
$\mu$	$\hat{\mu} = \bar{x}$	불편성, 효율성, 일치성 모두 만족
p	$\hat{p}$	불편성, 효율성, 일치성 모두 만족
$\sigma^2$	$\hat{\sigma^2} = s^2$	불편성(n-1) ※표본분산은 다른 여러 종류의 산포도를 측정하는 단위보다 상대적으로 효율성과 일치성이 있기 때문 에 사용!!

예제) {1,2,3,4,5}에서 표본크기가 3인 표본을 비복원으로 추출한다.

$$\mu = \frac{1 + 2 + 3 + 4 + 5}{5} = 3, \qquad \sigma^2 = \frac{1}{5} \left\{ (1 - 3)^2 + (2 - 3)^2 + (3 - 3)^2 + (4 - 3)^2 + (5 - 3)^2 \right\} = 2$$

(1) 세 통계량  $\overline{X}$ ,  $\widetilde{X}$ ,  $X_{(1)}$  값 중 불편추정량은 어떤 것인가 그리고 불편추정량 중 효율성이 좋은 것은?

표본	$\overline{X}$	$\widetilde{X}$	$X_{(1)}$
{1,2,3}	2	2	1
{1,2,4}	2.33	2	1
{1,2,5}	2.67	2	1
{1,3,4}	2.67	3	1
{1,3,5}	3	3	1
{1,4,5}	3.33	4	1
{2,3,4}	3	3	2
{2,3,5}	3.33	3	2
{2,4,5}	3.67	4	2
{3,4,5}	4	4	3

$$E(\overline{X}) = \frac{2 + 2.33 + \dots + 4}{10} = 3$$

$$S_{\overline{X}}^2 = 0.37038, S_{\overline{X}} = 0.60859$$

$$E(\overline{X}) = \frac{2 + 2 + \dots + 4}{10} = 3$$

$$S_{\overline{X}}^2 = 0.6667, S_{\overline{X}} = 0.81652$$

$$E(X_{(1)}) = \frac{1 + 1 + \dots + 3}{10} = 1.5$$

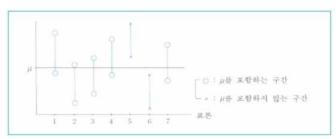
불편추정량 : 표본평균 $(\overline{X})$ 과 중앙값 $(\widetilde{X})$ 효율성 좋은 것 : 표본평균 $(\overline{X})$ 

=> 최종 추정량 선택: 표본평균(X)

## 구간추정 (Interval Estimation)

하나의 수치를 구하는 것이 아니라 추정량의 분포를 이용하여 표본으로부터 모수 값을 포함하리라고 예상되는 구간을 구하여 제시하는 것. 이 때 제시되는 구간을 **신뢰구간(confidence interval)** 이라 한다. 그리고 여러 번 구한 신뢰구간 중 추정하고자 하는 모수를 포함하고 있는 신뢰구간의 비율을 **신뢰수준(confidence level)** 이라 한다.

Example) '모평균  $\mu$ 에 대한 95% 신뢰구간'은 예를 들면 100차례 표본을 추출하여 신뢰구간을 구하였을 때, 그 100개의 신뢰구간 중 95개가 모수  $\mu$ 를 포함하리라고 예상한다는 의미이다.



[신뢰구간의 의미]

# $**모평균 <math>\mu$ 에 대한 신뢰구간

(1) 표본의 크기(n)가 큰 경우

표본의 크기가 n이고 평균과 표준편차가  $\overline{X}$ 와 s로 주어질 때  $\mu$ 에 대한  $100(1-\alpha)\%$  신뢰구간은

$$\left(\overline{X} - z_{\alpha/2} \frac{s}{\sqrt{n}} , \overline{X} + z_{\alpha/2} \frac{s}{\sqrt{n}}\right) \stackrel{\underline{\check{\varsigma}}}{-} \stackrel{\underline{\diamond}}{-} \overline{X} \pm z_{\alpha/2} \frac{s}{\sqrt{n}}$$

단, 모집단의 표준편차 $(\sigma)$ 가 알려져있으면  $s \rightarrow \sigma$ 로 대체한다.

(2) 표본의 크기(n < 30)가 작은 경우 (단, 모집단이 정규분포인 경우)

모집단의 분포가 정규분포이고 표본크기가 작을 때  $\frac{\overline{X}-\mu}{s/\sqrt{n}}$ 은 표준 정규분포가 아닌 t-분포를 따르게 된다. 따라서  $\mu$ 에 대한  $100(1-\alpha)\%$  신뢰구간은

$$\left(\overline{X} - t_{\alpha/2}(n-1) \frac{s}{\sqrt{n}} \;,\; \overline{X} + t_{\alpha/2}(n-1) \frac{s}{\sqrt{n}} \right) \; \stackrel{\tilde{\boxtimes}}{\lnot} \stackrel{\circlearrowright}{\leftarrow} \; \overline{X} \pm t_{\alpha/2}(n-1) \frac{s}{\sqrt{n}}$$

이 때 표준편차( $\sigma$ )는 알려져 있지 않은 것으로 간주한다.

- → 신뢰수준은 보통 90%, 95%, 99% 등을 사용한다.
- o  $\overline{X}\pm z_{\alpha/2}\frac{s}{\sqrt{n}}$ ,  $\overline{X}\pm t_{\alpha/2}(n-1)\frac{s}{\sqrt{n}}$  를  $100(1-\alpha)\%$ 오차범위(error margin) 라고 한다.
- $\rightarrow z_{\alpha/2}, t_{\alpha/2}(n-1)$  는 각 분포에서 상위  $\alpha/2$ 의 확률을 주는 값.

신뢰수준	90%	95%	99%
$z_{lpha/2}$	1.645	1.96	2.575

Note) (1) 표본의 크기가 큰 경우  $\mu$ 에 대한  $100(1-\alpha)\%$  신뢰구간의 유도

모집단에서 크기가 n인 충분히 큰 표본을 추출한다면, 표본평균  $\overline{X}$ 의 분포는 중심극한정리(CLT)에 의해

$$\overline{X} \sim N\!\!\left(\!\mu, \frac{\sigma^2}{n}\right) \Rightarrow \frac{\overline{X}\!\!-\!\mu}{\sigma/\sqrt{n}} \sim N(0, 1)$$

$$\alpha = 1 - P\left(\left|\frac{\overline{X} - \mu}{\sigma/\sqrt{n}}\right| < z_{\alpha/2}\right)$$
 로 두면,  $1 - \alpha = P\left(\left|\frac{\overline{X} - \mu}{\sigma/\sqrt{n}}\right| < z_{\alpha/2}\right)$  이코 이 때  $z_{\alpha/2}$  는

상위  $\alpha/2$ 의 확률을 주는 값으로 정한다. 그러면

$$\begin{split} 1 - \alpha &= P \bigg( \bigg| \frac{\overline{X} - \mu}{\sigma / \sqrt{n}} \bigg| < z_{\alpha/2} \bigg) = P \bigg( -z_{\alpha/2} \frac{\sigma}{\sqrt{n}} < \overline{X} - \mu < z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \bigg) \\ &= P (\overline{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}} < \mu < \overline{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}}) \end{split}$$

이므로, 신뢰구간은 
$$\left(\overline{X}-z_{\alpha/2}\frac{s}{\sqrt{n}},\overline{X}+z_{\alpha/2}\frac{s}{\sqrt{n}}\right)$$
 이 된다.

(2) 표본 크기가 작고, 모표준편차  $\sigma$ 를 모르는 경우  $\mu$ 에 대한  $100(1-\alpha)\%$  신뢰구간의 유도

$$t=rac{X-\mu}{s/\sqrt{n}}\sim t(n-1)$$
 를 이용하면 
$$1-\alpha==Pigg(-t_{lpha/2}(n-1)\leqrac{\overline{X}-\mu}{s/\sqrt{n}}\leq t_{lpha/2}(n-1)igg)$$
 
$$=P(\overline{X}-t_{lpha/2}(n-1)rac{s}{\sqrt{n}}\leq\mu\leq\overline{X}+t_{lpha/2}(n-1)rac{s}{\sqrt{n}})$$

이므로, 신뢰구간은 
$$\left(\overline{X}-t_{\alpha/2}(n-1)\frac{s}{\sqrt{n}},\overline{X}+t_{\alpha/2}(n-1)\frac{s}{\sqrt{n}}\right)$$
 이 된다.

### • t 분포 (t-distribution)

정규모집단  $N(\mu, \sigma^2)$ 으로부터 추출된 표본을  $X_1, \cdots, X_n$ 이라고 할 때, 표본평균과 표본분산을

$$\overline{X} = \frac{\Sigma X_i}{n}, \ s^2 = \frac{\Sigma (X_i - \overline{X})^2}{n-1}$$

이라고 정의하면, 표준화된 확률변수

$$t = \frac{\overline{X} - \mu}{s / \sqrt{n}}$$

는 자유도가 (n-1)인 t 분포를 따른다고 하고, 이를 기호로써 t(n-1)로 표현한다.

- → 자유도가 커질수록 표준정규분포에 가까워진다 ⇔ 표본의 크기가 클 수록 근사적으로 정규분포를 따른다
- $\rightarrow t_{\alpha}(r)$  : 상위  $\alpha$ 의 확률을 주는 값. 이 때 r은 자유도(d.f.)

Example) 우주선 제작에 쓰기 위해서 새롭게 개발된 합금의 평균 장력  $\mu$ 를 추정하고자 한다. 15개의 새 합금조각으로부터 장력을 측정한 결과 평균이 39.3, 표준편차가 2.6으로 나타났다.

새롭게 개발된 합금의 평균장력 μ에 대한 90% 신뢰구간을 구하라.

sol) 
$$\overline{X} \pm t_{\alpha/2}(n-1) \frac{s}{\sqrt{n}} = 39.3 \pm 1.761 \frac{2.6}{\sqrt{15}} = 39.3 \pm 1.18 \stackrel{\constraints}{=} \stackrel{\constraints}{=} (38.12, 40.48)$$

## 2. 모비율에 대한 추정

모집단의 크기가 매우 커서 그에 비해 표본의 크기가 작은 경우, 표본의 추출과정은 거의 서로 독립이므로 X의 분포는 모수가 (n,p)인 이항분포를 따른다.  $\to X \sim B(n,p)$ : 평균 np, 표준편차  $\sqrt{np(1-p)}$ 이로부터 표본비율인  $\hat{p} = \frac{\overline{X}}{n}$  의 기댓값과 표준편차를 구하면  $E(\hat{p}) = p$ ,  $S.E.(\hat{p}) = \sqrt{\frac{p(1-p)}{n}}$ .

## 모비율의 점추정

모수 : 모집단에서 A 라는 특성을 갖는 집단의 비율 : 모비율 p 자료 : 크기가 n인 표본에서 A 라는 특성을 갖는 개체의 수 : X

추정량 : 표본비율  $\hat{p} = \frac{\overline{X}}{n}$ 

표준오차 :  $S.E.(\hat{p}) = \sqrt{\frac{p(1-p)}{n}}$  , 추정된 표준오차 :  $\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$ 

\* 표본의 크기가 큰 경우에  $\hat{p}$ 는 근사적으로 평균이 p이고 분산이  $\frac{p(1-p)}{n}$  인 정규분포를 따른다.

이를 표준화 하면  $Z=rac{\hat{p}-p}{\sqrt{rac{p(1-p)}{n}}}=rac{\hat{p}-p}{\sqrt{rac{\hat{p}(1-\hat{p})}{n}}}\sim N(0,1)$  이다.

- Example) 어느 통신판매회사에서는 하나의 새로운 상품을 그 달의 특별상품으로 판매하고자 한다. 그 회사에서 관리하는 만 명의 고객명단에서 임의로 250명을 추출하여 안내책자를 발송한 결과 그 중 70명이 구입을 희망하였다고 한다. 이 표본자료에 근거해서 전체 고객 중 그 상품에 대한 구입을 원하는 모비율(p)을 추정하고, 그 추정량의 표본오차를 구하여라.
  - sol) 모비율 p에 대한 추정량은 표본비율이므로 p의 추정치 :  $\hat{p} = \frac{70}{250} = 0.28$  이고,

 $\hat{p}$ 의 표준오차를 추정하면,  $\hat{p}$ 의 추정된 표준오차 :  $\sqrt{\frac{\hat{p}(1-\hat{p})}{n}} = \sqrt{\frac{0.28 \times 0.72}{250}} = 0.028$  이다

# 모비율의 구간추정

- \*\*모비율 p에 대한  $100(1-\alpha)$ % 신뢰구간
- 모비율 p는 알려져 있지 않으나 표본 크기 n이 충분히 크면 p 대신에 표본비율  $\hat{p}$ 를 사용할 수 있다.

$$\left(\hat{p} - z_{\alpha/2}\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}\;, \hat{p} + z_{\alpha/2}\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}\;\right)\; \stackrel{\mathfrak{S}}{\rightleftharpoons}\; \hat{p} \pm z_{\alpha/2}\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

- Example) 한 도시의 노동인구 500명 중 41명이 실업자로 나타났다고 하였다. 그 도시의 실업률 p에 대한 95% 신뢰구간을 구하여라.
  - sol) p에 대한 95% 신뢰구간은

$$\hat{p} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} = \frac{41}{500} \pm 1.96 \sqrt{\frac{0.082 \bullet 0.918}{500}} = 0.082 \pm 0.024 \ \ \stackrel{\S}{\stackrel{\bullet}{\hookrightarrow}} \ \ (0.058, 0.106) \ \$$
이다.

## 3. 표본 크기의 결정

-오차가 d 이하로 될 확률이 최소한  $100(1-\alpha)$ %가 되도록 하기 위해서 필요한 최소의 표본크기

 모수	표본크기
모평균	$n \geq \left(z_{lpha/2}rac{\sigma}{d} ight)^2$
모비율	$n \geq \left(z_{\alpha/2}\frac{\sigma}{d}\right)^2 p(1-p)$ *사전정보 없을 시 $p=0.5$ 이용

유도  $\rightarrow$  모집단이 정규분포이고, 표준편차  $\sigma$ 가 주어져 있을 때

-모평균의 경우 오차가 d 이하로 될 확률이 최소한  $100(1-\alpha)\%$  :  $P(\left|\overline{X}-\mu\right| \leq d) \geq 1-\alpha$ 

-표준화된 확률변수의 분포가 표준정규분포를 따르므로  $P\!\!\left(\frac{|\overline{X}-\mu|}{\sigma/\sqrt{n}}\! \le z_{lpha/2}\!\right)\!\!=1-lpha$ 

$$\Rightarrow z_{lpha/2} rac{\sigma}{\sqrt{n}} \leq d$$
 , 이 식을  $n$ 에 대하여 풀면  $n \geq \left(z_{lpha/2} rac{\sigma}{d}
ight)^2$  이 된다.

※ 모집단이 정규분포라는 가정이 없다면, 표본의 크기가 30이상으로 구해졌을 때에만 사용가능하다.

Example) 호수의 성분을 연구하는 한 학자가 호수성분의 하나인 인산염의 무게 분포에 관심이 있다고 한다. 그 학자가 단위부피당 평균무게(μ)를 추정하고자 하는데, 이제끄지의 자료에 의하면 단위부피당 인산염의 무게의 표준편차 σ=4를 갖는다고 한다. 평균무게 μ에 대한 오차가 0.75 이하가 될 확률이 최소한 90% 가 되기 위해서는 어느 정도 크기의 표본을 조사하여야 하겠는가?

sol) 
$$z_{0.05}=1.645,\ d=0.75.\ \sigma=4 \implies n\geq \left(1.645\left(\frac{4}{0.75}\right)\right)^2=76.97,$$
 따라서  $n$ 은 최소한 77이상이어야 한다.

Example) 공중보건에 관한 조사에서 시력장애자의 비율을 추정하고자 한다. 만약 이 조사에서 얻어지는 p에 대한 추정량의 오차가 0.05 이하가 될 확률이 최소한 98%가 되기를 원한다면 몇명을 대상으로 시력장애 여부를 조사하여야겠는가?

sol)  $n \ge 0.5(1-0.5) \left(\frac{2.33}{0.05}\right)^2 = 542.9$ , 따라서 최소한 543이어야 한다.

# 4. 모표준편차에 대한 추정

- 모집단이 정규분포를 따른다고 가정한다.

점추정의 경우 :  $\sigma^2$ 의 추정량으로  $s^2$  사용하고, 모표준편차의 추정량으로 표본표준편차 s를 사용

구간추정의 경우 :  $s^2$ 의 분포가 필요!  $\rightarrow \chi^2$ (카이제곱) 분포와 연관

### 모표준편차의 구간추정

# • $\chi^2$ 분포 ( $\chi^2$ distribution)

정규모집단  $N(\mu,\sigma^2)$ 으로부터 추출된 표본을  $X_1,\cdots,X_n$ 이라고 할 때

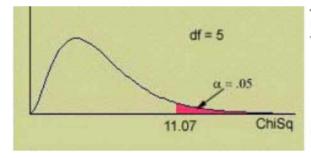
$$\chi^2 = \frac{\sum_{i=1}^{n} (X_i - \overline{X})^2}{\sigma^2} = \frac{(n-1)s^2}{\sigma^2} \sim \chi^2(n-1)$$

은 자유도가 (n-1)인  $\chi^2$  분포를 따른다고 하고, 이를 기호로써  $\chi^2(n-1)$ 로 표현한다.

- →이 분포는 정규분포나 t분포와 달리 확률밀도함수가 양수쪽에만 퍼져있고 오른쪽에 긴 꼬리를 갖는 비대칭형이다.
- →자유도가 클수록 0으로부터 멀리 떨어져서 넓게 분포한다.
- $\rightarrow \chi^2_{\alpha}(r)$  : 자유도가 r인 확률변수  $\chi^2$ 에 대하여 상,하위  $\alpha$ 의 확률을 주는 값

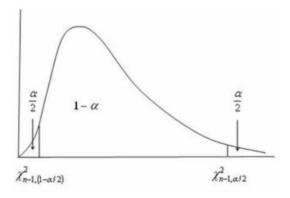
# $\chi^2$ 분포의 확률 계산하기

자유도(n-1)와  $\alpha$ 값에 따라  $\chi^2$  분포표를 이용하여 상위  $\alpha$ 의 확률을 구한다.



X.100	X 2 050	X 2 .025	X 2010	X 2 .005	df
2.70554	3.84146	5.02389	6.63490	7.87944	1
4.60517	5.99147	7.37776	9.21034	10.5966	2
6.25139	7.81473	9.34840	11.3449	12.8381	3
7.77944	9.48773	11.1433	13.2767	14.8602	4
9.23635	11.0705	12.8325	15.0863	16.7496	5
10.6446	12.5916	14.4494	16.8119	18.5476	6
12.0170	14.0671	16.0128	18.4753	20.2777	7

Example)  $\chi^2$  분포표에서 자유도가 17인  $\chi^2$  분포의 상, 하위 5%의 확률을 주는 값을 찾아라.



sol) 상위 5%의 확률을 주는 값은  $\chi^2_{0.05}(17) = 27.59$ 이고, 하위 5%의 확률을 주는 값은  $\chi^2_{0.05}(17) = 8.67$ 이다.

\*\*모표준편차  $\sigma$ 의  $100(1-\alpha)\%$  신뢰구간

$$\left(s\sqrt{\frac{(n-1)s^2}{\chi^2_{\alpha/2}(n-1)}}\;,s\sqrt{\frac{(n-1)s^2}{\chi^2_{1-\alpha/2}(n-1)}}\;\right)$$

Note) 표본분산  $s^2$ 을 이용한  $\sigma^2$ 의 신뢰구간을 우선 구하자.

$$\frac{(n-1)s^2}{\sigma^2} \sim \chi^2(n-1) \quad \text{임을 이용하면 } P(\chi^2_{1-\alpha/2}(n-1) < \frac{(n-1)s^2}{\sigma^2} < \chi^2_{\alpha/2}(n-1)) = 1-\alpha$$

$$\Rightarrow P(\frac{(n-1)s^2}{\chi^2_{\alpha/2}(n-1)} < \sigma^2 < \frac{(n-1)s^2}{\chi^2_{1-\alpha/2}(n-1)}) = 1-\alpha$$

$$\Rightarrow \left(\frac{(n-1)s^2}{\chi^2_{\alpha/2}(n-1)}, \frac{(n-1)s^2}{\chi^2_{1-\alpha/2}(n-1)}\right) : \sigma^2 \text{의 신뢰구간}$$

$$\Rightarrow \left(s\sqrt{\frac{(n-1)s^2}{\chi^2_{\alpha/2}(n-1)}}, s\sqrt{\frac{(n-1)s^2}{\chi^2_{1-\alpha/2}(n-1)}}\right) : \sigma \text{의 신뢰구간}$$

Example) 볼트와 너트를 생산하는 한 공장에서는 제품의 품질이 얼마나 균일하게 유지되는지를 검사하려고 10개의 볼트를 추출하여 지름을 측정하고 그 표준편차를 구하였더니 0.4였다. 그 공장에서 생산되는 볼트의 지름이 정규분포를 따른다는 가정 하에 σ의 90% 신뢰구간을 구하여라.

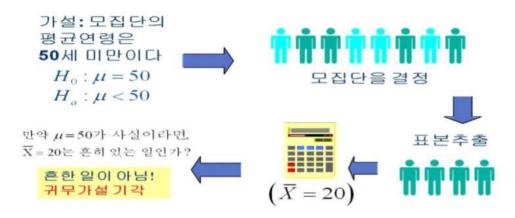
sol) 
$$n=10$$
,  $\chi^2_{0.05}(9)=16.92$ ,  $\chi^2_{0.95}(9)=3.33$ 

$$\sigma^2 의 90\% 신뢰구간 : \left(\frac{(n-1)s^2}{\chi^2_{\alpha/2}(n-1)}, \frac{(n-1)s^2}{\chi^2_{1-\alpha/2}(n-1)}\right) = \left(\frac{9\times(0.4)^2}{16.92}, \frac{9\times(0.4)^2}{3.33}\right) = (0.085, 0.432)$$
∴  $\sigma$ 의 신뢰구간은  $(\sqrt{0.085}, \sqrt{0.432}) = (0.29, 0.66)$  이다.

## 5. 가설 검정

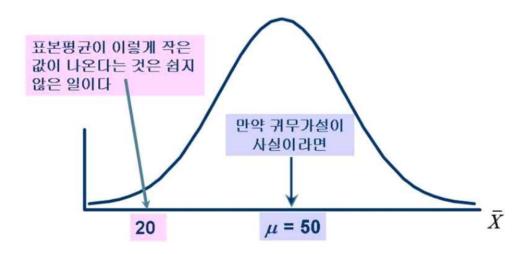
## 가설검정 (Testing of Hypothesis)

모집단의 모수나 분포에 대하여 가설을 설정하고, 이 가설의 옳고 그름을 표본의 정보를 이용하여 검정하는 방법



[가설검정 과정 및 원리]

# $ar{X}$ 의 표본분포



결론적으로 *μ* = **50**라는 귀무가설은 기각됨

## 통계적 가설 (Statistical Hypothesis)

모집단의 특성 또는 모수에 대한 대립되는 두 가지 주장에 대하여 통계적으로 다루기에 편리하도록 정리한 것

### • 가설의 종류

- (1) 대립가설 ( $H_1$ : alternative hypothesis)
  - 표본에서 나타난 정보를 통해서 밝히고자 하는 가설 → "입증하려는 가설"
- (2) 귀무가설 ( $H_0$ : null hypothesis)
  - 대립가설에 반대되는 가설
    - → "대립가설을 입증할 수 없을 때 대립가설을 무효화 시키면서 받아들이는 가설"

## • 가설검정 규칙

귀무가설		대립	가설
$H_0: \theta = \theta_0$		$H_1: \theta \neq \theta_0$	양측검정(two-sided test)
$H_0:  heta \leq  heta_0$ $H_0:  heta \geq  heta_0$	$H_0:\theta=\theta_0$	$H_1: \theta > \theta_0$ $H_1: \theta < \theta_0$	단측검정(one-sided test)

- $\rightarrow$  귀무가설은 모수를 특정한 값으로 표현한다.  $H_0: \theta = \theta_0$   $(\theta_0: 모수의 특정한 값)$
- → 대립가설은 귀무가설에서 지적한 모수의 값이 아닌 어떤 영역으로 나타낸다.

Example) 어느 전구의 제조공정에서는 평균수명이 1500시간이고 표준편차가 100이 되도록 품질관리를 하고 있다. 품질을 개선하기 위하여 어느 팀에서 새로운 공법을 개발하였으며 새 공법에 의하면 평균수명이 증가한다고 주장한다. (다만, 새 공법의 특성은 기존의 공법과 같아서 표준편차가 100으로 가정할 수 있으며, 생산비용도 같다고 가정한다.)

## • 검정통계량 (test statistic)

- 검정에 사용하기 위하여 표본자료에서 구한 통계량
- 일반적으로 검정하려는 모수의 점추정량 또는 점추정량을 표준화한 것을 사용

검정하려는 모수		표준화된 검정통계량
$\mu$ (정규분포 모집단의 평균)	σ를 알 때	$Z = \frac{\overline{X} - \mu_0}{\sigma / \sqrt{n}} \sim N(0, 1)$
	$\sigma$ 를 모를 때	$T = \frac{\overline{X} - \mu_0}{s / \sqrt{n}} \sim t(n-1)$
p     (모비율)	$np \ge 5, n(1-p) \ge 5$	$Z = \frac{\hat{p} - p_0}{\sqrt{p_0(1 - p_0)/n}} \sim N(0, 1)$

### • 검정의 오류 (test error)

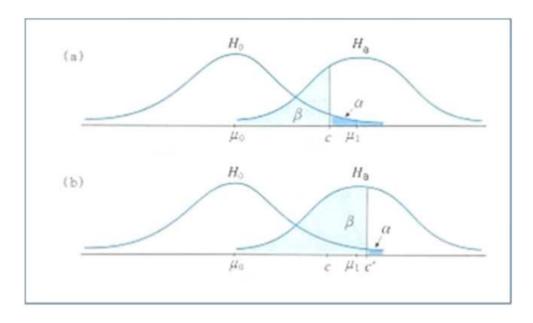
- 가설을 채택하거나 기각할 때 확률적으로 틀릴 가능성

## <오류의 종류>

실제상황 검정결과	$H_0$ 가 사실	$H_1$ 이 사실
$H_0$ 를 기각못함	옳은결정 : $1-\alpha$	제 2종 오류 (type II error) : $eta$
$H_0$ 를 기각 ( $H_1$ 채택)	제 1종 오류 (type I error) : $lpha$	옳은 결정 : 1- <i>β</i>

- → 제 1종 오류 : 귀무가설이 맞을 때 귀무가설을 기각하는 오류
- → 제 2종 오류 : 귀무가설이 틀리는데 귀무가설을 기각하지 않는 오류
- $\rightarrow$  두 개의 가설  $H_1$ 과  $H_0$ 을 쓸 때  $H_0$  대  $H_1$  으로 쓴다.
- ightarrow lpha=P(제1종 오류 $)=P(H_0$ 기각  $\mid H_0$ 사실) eta=P(제2종 오류 $)=P(H_0$ 채택  $\mid H_1$ 사실)
- \*\* 검정력(power,  $1-\beta$ ) :  $1-\beta = P(H_0$ 기각 |  $H_1$ 사실)

Example)  $H_0: \mu = \mu_0$  ,  $H_1: \mu > \mu_0$  의 가설에서  $H_1$ 의 대표값이  $\mu_1$ 일 때, 임계값 c에 의해서  $\alpha$ ,  $\beta$ 를 결정



- $\rightarrow$  이상적인 목표는  $\alpha$ ,  $\beta$ 를 동시에 작게하는 것이지만,  $\alpha$ 가 작아지면  $\beta$ 가 커지는 모순이 발생
- $\rightarrow \alpha$ 를 정하고 그 중  $\beta$ 를 최소로 하는 가설검정 시행

# • 유의수준 (significance level : $\alpha$ ) 결정 : 제 1종 오류의 최대값

- $\alpha = \max P(\text{제1종 오류}) = \max P(H_0 \text{기각 } \mid H_0 \text{사실})$
- 귀무가설이 참인데도 불구하고 이를 기각하는 확률로 위험률이라고도 한다.
- 자료와 관련된 학문 분야에서 이미 사용되고 있는 유의수준 또는 논문 등을 참고하여 유의수준을 결정한다.

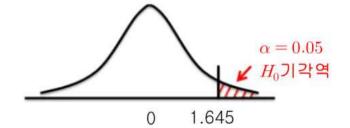
### • 기각역 (rejection region / critical region)

- 귀무가설을 기각할 수 있는 검정통계량의 영역으로 대립가설의 형태에 따라 기각역이 달라진다.
- → 기각역에 의한 판정 : 유의수준에 따라 기각역을 정하고, 검정통계량이 기각역에 속하면 귀무가설을 기각

Example)  $H_1: \mu > \mu_0 \ (\alpha = 0.05)$ 

검정통계량 :  $\overline{X} \Rightarrow R : \overline{X} \geq c, \ c = \mu_0 + 1.645 \frac{s}{\sqrt{n}}$ 

검정통계량 :  $\frac{\overline{X} - \mu_0}{s/\sqrt{n}} \Rightarrow R : \frac{\overline{X} - \mu_0}{s/\sqrt{n}} \ge 1.645$ 



# • 유의확률 (significance probability / p-value)

- *귀무가설이 사실일 때* 표본이 대립가설 방향으로 검정통계량의 값보다 더 어긋나게 될 확률
- 주어진 검정통계량의 값으로부터  $H_0$ 를 기각하게 하는 최소의 유의수준
- $\Rightarrow p$  값이 작은 경우 : 귀무가설이 참일 때 나오기 힘든 경우가 나온 것. i.e. p 값이 작을수록, 귀무가설을 기각하는 쪽으로 신뢰

 $p-value \leq \alpha$  : 유의수준  $\alpha$ 에서  $H_0$  기각 (통계적으로 유의하다)

 $p-value > \alpha$  : 유의수준  $\alpha$ 에서  $H_0$  기각 못함 (통계적으로 유의하지 않다)

# ※ 가설검정 절차

- ① 귀무가설과 대립가설을 설정한다.
- ② 주어진 문제의 특성에 따라 유의수준  $\alpha$ 를 결정한다.
- ③ 표본 자료에서 검정통계량을 계산한다.
- ④ 가설검정결론
  - (i) 기각역 사용
    - 유의수준에 따라 기각역을 구한다.
    - 검정통계량이 기각역에 속하면  $H_0$ 을 기각한다.

# (ii) p값(유의확률) 사용

- 검정통계량을 이용하여 p값을 구한다.
- $p \le \alpha$  이면  $H_0$ 를 기각한다.

# 5-1. 모평균의 가설검정

# ① 가설

귀무가설		대립가설
	$H_1: \mu \neq \mu_0$	양측검정(two-sided test)
$H_0:\mu=\mu_0$	$H_1: \mu > \mu_0$	단측검정(one-sided test)
	$H_1: \mu < \mu_0$	단측검정(one-sided test)

- ② 유의수준  $\alpha$  정하기 : 0.01, 0.05
- ③ 검정통계량 : 귀무가설이  $H_0: \mu = \mu_0$  인 경우 검정통계량은

$\sigma$ 를 알 때	$\sigma$ 를 알 때 $\sigma$ 를 모를 때, $n$ 이 클 때 $(n \geq 30)$	
$Z = \frac{\overline{X} - \mu_0}{\sigma / \sqrt{n}} \sim N(0, 1)$	$Z = \frac{\overline{X} - \mu_0}{s/\sqrt{n}} \sim N(0,1)$	$T = \frac{\overline{X} - \mu_0}{s / \sqrt{n}} \sim t(n-1)$

# ④ 기각역 & 유의확률

			대립가설		
			$H_1: \mu > \mu_0$	$H_1: \mu < \mu_0$	$H_1: \mu \neq \mu_0$
			a a	a	$\frac{\alpha}{2}$
	$Z = \frac{\overline{X} - \mu_0}{\sigma / \sqrt{n}}$	기각역	$R = \left\{Z \ge z_{\alpha}\right\}$	$R = \left\{ Z \le - z_{\alpha} \right\}$	$R = \left\{ \begin{matrix} Z \leq -  z_{\alpha/2}  , \\ Z \geq  z_{\alpha/2}  , \end{matrix} \right\}$
검 정 통	또는 $Z = \frac{\overline{X} - \mu_0}{s/\sqrt{n}}$	유의확률 (p-값)	$P(Z \ge z)$	$P(Z \leq z)$	$z > 0: 2 \times P(Z \ge z)$ $z < 0: 2 \times P(Z \le z)$
<sub>이</sub> 계 량	$T = \frac{\overline{X} - \mu_0}{s / \sqrt{n}}$	기각역	$R = \big\{ T \geq t_{\alpha}(n-1) \big\}$	$R = \left\{ T \le -t_{\alpha}(n-1) \right\}$	$R = \left\{ \begin{aligned} T \leq &-t_{\alpha/2}(n-1) , \\ T \geq & t_{\alpha/2}(n-1) \end{aligned} \right\}$
	$s/\sqrt{n}$	유의확률 (p-값)	$P(T \ge t)$	$P(T \leq t)$	$\begin{array}{ccc} t > 0: & 2 \times P(T \ge t) \\ t < 0: & 2 \times P(T \le t) \end{array}$

Example) 어느 다이어트 방법을 소개하는 책자에서 주장하기를 그 다이어트 방법을 이용하면 5주 동안 10kg 넘게 체중을 줄일 수 있다고 한다. 그 다이어트 방법을 이용하여 56명을 대상으로 5주 동안의 체중 감소량을 조사하였더니 평균이 10.5kg, 표준편차가 4.5kg이었다고 한다. 이 자료에 근거해서 그 책자의 주장이 옳다고 할 수 있는가? 유의수준 5%에서 검정하시오.

sol) 
$$n = 56$$
,  $\bar{x} = 10.5$ ,  $s = 4.5$ 

- ① 가설:  $H_0: \mu = 10, H_1: \mu > 10$
- ② 검정통계량 :  $z = \frac{10.5 10}{4.5 / \sqrt{56}} = 0.83$
- ③ 기각역 :  $R: \{Z \geq z_{0.05} = 1.645\}$ 유의확률(p-값) :  $P(Z \geq 0.83) = 1 - P(Z < 0.83) = 1 - 0.7967 = 0.2033$
- ④ 결론 : (i) 기각역 기준 : 검정통계량이 z=0.83으로 임계치 1.645보다 작으므로  $H_0$  기각역에 속하지 않는다. 그러므로  $H_0$ 를 기각할 수 없다. 즉, 유의수준 5%에서 책자의 주장이 옳다고 할 수 없다.
  - (ii) 유의확률 기준 : 유의확률이 0.2033으로 유의수준 0.05보다 크므로  $H_0$ 를 기각할 수 없다. 즉, 유의수준 5%에서 책자의 주장이 옳다고 할 수 없다.
- Example) 한국 청소년들의 하루 평균 TV시청 시간에 대하여 가설검정을 한다. 한편은 시청 시간이 하루 3시간 이라고 주장하고 다른 한편은 "그렇지 않다"라고 주장한다. 그래서 100명의 청소년을 대상으로 시청 시간을 조사해 본 결과 아래와 같은 결과가 나왔다. 유의수준 5%로 검정하시오.
  - sol)  $\overline{x}=2.75$ 시간이고.  $\sigma=1$ 
    - ① 가설:  $H_0: \mu = 3, H_1: \mu \neq 3$
    - ② 검정통계량 :  $z = \frac{\overline{X} \mu_0}{\sigma / \sqrt{n}} = \frac{2.75 3}{1 / \sqrt{100}} = -2.5$
    - ③ 기각역  $R: \{|z| \geq z_{0.025} = 1.96\} \Rightarrow R: \{z \leftarrow 1.96, z > 1.96\}$ 유의확률 $(p-दो): P\{|Z| > 2.5\} = P(z \leftarrow 2.5) + P(z > 2.5) = 0.0062 \times 2 = 0.0124$
    - ④ 결론
      - -z=-2.5는 기각역 -1.96 보다 작으므로 기각역에 속한다. 따라서 유의수준 5%에서 귀무가설을 기각할 수 있다. 즉, 이 자료에 의하면 유의수준 5%에서 청소년들의 하루 평균 TV시청이 3시간이 아니라고 할 수 있다.
      - -p값이 0.0124로 유의수준  $\alpha = 0.05$ 보다 작으므로 귀무가설을 기각할 수 있다. 즉, 이 자료에 의하면 유의수준 5%에서 청소년들의 하루 평균 TV시청이 3시간이 아니라고 할 수 있다.

Example) 어느 도시의 보건복지과에서는 그 도시의 상수원인 어느 호수의 수질에 관심이 있다고 한다. 수질을 나타내는 하나의 수치로 단위부피당 평균 세균 수가 있는데, 그 수가 200이상이면 상수원으로 적합

주실을 나타내는 하나의 주지로 단위부피당 평균 세균 주가 있는데, 그 주가 200이상이면 상구원으로 적합하지 않다고 한다. 호수의 열 군데에서 물을 떠서 조사한 결과 단위부피당 세균수가 다음과 같이 나타났다

175 190 215 198 184 207 210 193 196 180

이 자료료부터 호수의 단위부피당 평균 세균  $\phi(\mu)$ 가 200보다 적다고 주장할 수 있겠는가? (단, 호수의 단위부피당 세균 수는 정규분포를 따른다고 가정하자)

sol) 
$$n = 10$$
,  $\bar{x} = 194.8$ 

$$s^{2} = \frac{\Sigma x^{2} - \frac{(\Sigma x)^{2}}{n}}{n - 1} = \frac{381024 - \frac{1948^{2}}{10}}{9} = 172.62, \ s = \sqrt{172.62} = 13.14$$

① 가설 :  $H_0: \mu = 200.$   $H_1: \mu < 200$ 

② 검정통계량 : 
$$t = \frac{\overline{X} - \mu_0}{s/\sqrt{n}} = \frac{194.8 - 200}{13.14/\sqrt{10}} = -1.25$$

③ 기각역 :  $R: \{T \leq -t_{0.05}(9) = -1.833\}$ 

④ 결론 :  $t=-1.25>-t_{0.05}(9)=-1.833$  이므로  $H_0$ 을 기각할 수 없다. 즉, 호수의 단위 부피당 평균 세균 수 $(\mu)$ 가 200보다 적다고 할 만한 충분한 근거가 없다.

# 5-2. 모비율의 가설검정 (대표본인 경우)

### ① 가설

귀무가설		대립가설
	$H_1: p \neq p_0$	양측검정(two-sided test)
$H_0:p=p_0$	$H_1: p > p_0$	단측검정(one-sided test)
	$H_1 : p < p_0$	단측검정(one-sided test)

② 유의수준  $\alpha$  정하기 : 0.01, 0.05

③ 검정통계량 : 귀무가설이  $H_0: p = p_0$  인 경우 검정통계량

$$Z = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0 (1 - p_0)}{n}}} \sim N(0, 1)$$

# ④ 기각역 & 유의확률

	대립가설		
	$H_1: p > p_0$	$H_1: p < p_0$	$H_1: p \neq p_0$
	α	a	$\frac{\alpha}{2}$
기각역	$R = \big\{Z \geq  z_{\alpha}\big\}$	$R = \big\{Z \!\leq\! - z_{\alpha}\big\}$	$R = \left\{ \begin{matrix} Z \! \leq \! -z_{\alpha/2}, \\ Z \! \geq z_{\alpha/2} \end{matrix} \right\}$
유의확률 (p-값)	$P(Z \geq z)$	$P(Z \leq z)$	$z > 0: 2 \times P(Z \ge z)$ $z < 0: 2 \times P(Z \le z)$

Example) 어떤 특정 암의 경우에 수술을 시행한 후 완치되는 비율(5년 이상 생존비율)이 30%라고 한다. 이 암에 걸린 60명의 환자를 대상으로 수술 뿐 아니라 수술 전후에 일정기간 방사선치료를 병행하였더니 60명 중 27명이 완치되었다고 한다. 이 자료로부터 수술만 하는 것보다 방사선 치료를 병행하는 것이 암의 완치율 (p)을 높이는데 효과가 있다고 할 수 있는지 검정하라.

sol) ① 가설 :  $H_0: p = 0.3, H_1: p > 0.3$ 

② 검정통계량 : 
$$z = \frac{\hat{p} - p_0}{aqrt \frac{p_0(1 - p_0)}{n}} = \frac{0.45 - 0.3}{\sqrt{\frac{0.3 \times 0.7}{60}}} = 2.546 \ (\hat{p} = \frac{27}{60} = 0.45)$$

③ 기각역 :  $R: \{Z > z_{0.05} = 1.645\}$ 

p-3:  $P(Z \ge 2.54) = 0.0055$ 

④ 결론: 귀무가설을 기각할 수 있다. 즉, 자료로부터 방사선치료의 병행이 암치료에 있어서 완치율을 높이는데 효과가 있다고 할 수 있다.

# 5-3. 모표준편차에 대한 가설검정 (모집단이 정규분포인 경우)

## ① 가설

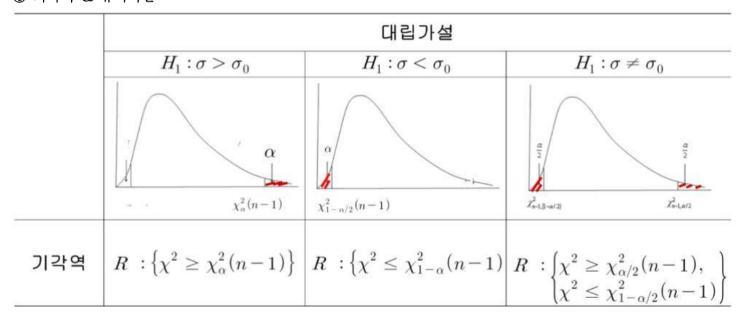
귀무가설		대립가설
	$H_1:\sigma\neq\sigma_0$	양측검정(two-sided test)
$H_0:\sigma=\sigma_0$	$H_1:\sigma>\sigma_0$	단측검정(one-sided test)
	$H_1: \sigma < \sigma_0$	단측검정(one-sided test)

② 유의수준  $\alpha$  정하기 : 0.01, 0.05

③ 검정통계량 : 귀무가설이  $H_0: \sigma = \sigma_0$  인 경우 검정통계량

$$\chi^2 = \frac{(n-1)s^2}{\sigma_0^2} \sim \chi^2(0,1)$$

# ④ 기각역 & 유의확률



Example) 볼트와 너트를 생산하는 한 공장에서는 제품의 품질이 얼마나 균일하게 유지되는지를 검사하려고 10개의 볼트를 추출하여 지름을 측정하고 그 표준편차를 구하였더니 0.4였다. σ가 0.2 보다 크다고 할 수 있는지 유의수준 0.05로 검정하라.

sol) ① 가설 :  $H_0:\sigma=0.2$  vs  $H_1:\sigma>0.2$ 

② 검정통계량 :  $\chi^2 = \frac{(n-1)s^2}{\sigma_0^2} = \frac{9 \times 0.4^2}{0.2^2} = 36$ 

③ 기각역 :  $R:\chi^2 \geq \chi^2_{0.05}(9) = 16.92$ 

④ 결론 : 검정통계량의 값이 기각역에 포함되므로 주어진 자료로부터  $\sigma$ 가 0.2보다 크다고 할 수 있다.

# 5-4. 신뢰구간과 양측검정의 관계

모수  $\theta$ 에 대한  $100(1-\alpha)$ %의 신뢰구간이 (L, U)로 구해졌을 때,

가설  $H_0: \theta = \theta_0$  vs  $H_1: \theta \neq \theta_0$  에 대하여 유의수준  $\alpha$ 로 검정을 시행할 때의 결론은 다음과 같다.

$$\theta_0 \in (L, U) \Leftrightarrow H_0$$
를 기각할 수 없다.

$$\theta_0 \not\in (L, U) \Leftrightarrow H_0$$
를 기각할 수 있다.

- ※ 신뢰구간은 한번 구하는 것으로 동시에 여러 귀무가설에 대한 양측 검정 결론을 얻을 수 있다.
  - ⇒ 신뢰구간이 좀 더 포괄적 추론의 과정
- Example) 정규모집단으로부터 크기가 9인 표본을 추출하여 평균과 표준편차를 계산하였더니 각각 x=8.3과 s=1.2 였다고 한다. 모평균  $\mu$ 에 대한 95% 신뢰구간을 구하고, 유의수준 5%로 가설  $H_0: \mu=8.5$  vs  $H_1: \mu\neq 8.5$ 를 검정하라.
  - sol) μ에 대한 95% 신뢰구간

$$\overline{X} \pm t_{0.025,8} \frac{s}{\sqrt{n}} = 8.3 \pm 2.306 \frac{1.2}{\sqrt{9}} = 8.3 \pm 0.9224, \,\, \Xi \succeq \,\, (7.38, 9.22)$$

• 가설검정

가설 :  $H_0: \mu = 8.5$  vs  $H_1: \mu \neq 8.5$ 

검정통계량 : 
$$t = \frac{8.3 - 8.5}{1.2/\sqrt{9}} = -0.5$$
 , 기각역 :  $|t| > 2.306$ 

# 제 12 장. 두 모집단의 비교

Example) -사무직과 생산직의 임금의 비교

- -수도권과 지방 고등학생들 간의 학력 비교
- -우리나라와 다른 나라의 물가 비교
- -두 종류의 강의방법에 의한 학습효과 비교
- -두 치료제의 효능 비교
- -두 종자의 생산량 비교
- -두 생산 공장의 불량률 비교
- -새로운 치료제의 효능

### Example) -두 치료제의 효능 비교:

10명의 환자에게 서로 다른 두 치료제를 투여함으로써 A와 B 두 치료제의 효능을 비교하려고 한다. 먼저 5명의 환자를 무작위로 추출하여 A 치료제를 투여하고, 나머지 5명의 환자에게는 B 치료제를 투여 하여 치료효과를 측정한다.

-새로운 고혈압 치료제의 효능:

고혈압을 가지고 있는 10명의 환자에게 새로운 치료제를 투여함으로써 약의 효능을 비교하려고 한다. 약 복용 전의 혈압, 일주일간 복용 후의 혈압을 재어 차이가 있는지 비교한다.

## ※ 두 개의 독립표본

서로 독립인 두 개의 모집단에서 각각 랜덤표본을 추출한 후 자료를 얻어 비교하는 방법

확률표본  $X_1, \dots, X_n$  :  $N(\mu_1, \sigma_1^2)$  인 모집단으로부터 추출

확률표본  $Y_1, \, \cdots, \, Y_m : N(\mu_2, \sigma_2^2)$  인 모집단으로부터 추출

 $\Rightarrow X_1, \dots, X_n$  와  $Y_1, \dots, Y_m$ 는 서로 독립인 확률표본이다.

# ※ 두 모집단의 평균차이에 대한 추정

(1) 
$$\mu_1-\mu_2$$
 의 점추정량 :  $\widehat{\mu_1-\mu_2}=\overline{X}-\overline{Y}$ 

(2) 
$$\mu_1 - \mu_2$$
 의 구간추정 :

$$\overline{X} - \overline{Y} \sim N \left( \mu_1 - \mu_2, \frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m} \right) \Rightarrow \frac{(\overline{X} - \overline{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}}} \sim N(0, 1)$$

(1) 
$$\mu_1-\mu_2$$
 의 점추정량 :  $\widehat{\mu_1-\mu_2}=\overline{X}-\overline{Y}$ 

(2) 
$$\mu_1 - \mu_2$$
 의 구간추정 :

$$\overline{X} - \overline{Y} \sim N \left( \mu_1 - \mu_2, \frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m} \right) \Rightarrow \frac{(\overline{X} - \overline{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}}} \sim N(0, 1)$$